Sovereign-IQ (SIQ)
综合报告

v2.1

System overview / workflow / technical architecture

2026-04-09

2026 Professional Edition

目 录

Sovereign-IQ (SIQ) 综合报告

第一部分：项目摘要

一、项目概述
二、作品描述：亮点与特点
三、技术创新点：NVIDIA技术栈深度应用
四、团队贡献
五、未来展望
六、项目影响力与社会价值

第二部分：系统角色与工作机制

第一章：七位Agent角色详解
第二章：工作机制与流程
第三章：协同机制与自我进化
第四章：SIQ系统的独特价值
第五章：结语

第三部分：技术架构深度

第一章：系统架构总览
第二章：硬件基础设施 - DGX Spark详解
第三章：大模型层 - 262K超长上下文
第四章：向量数据库层 - Milvus 2.6.13
第五章：Multi-Agent架构实现
第六章：工具集成与外部API
第七章：安全与审计
第八章：性能优化与未来演进
第九章：总结

Sovereign-IQ (SIQ) 综合报告

第一部分：项目摘要

项目名称：	Sovereign-IQ (SIQ) 主权智感智能投研决策系统

一、项目概述

1.1 项目背景

中国一级市场投资长期面临**投研效率低、专业盲区多、知识流失严重**的痛点。传统投研依赖1-2人负责一个项目，数周完成尽调，容易错过最佳投资窗口，且决策缺乏可追溯性。

1.2 项目目标

打造**中国首个面向一级市场投资的多Agent智能投研决策系统**，为每位投资人配备一个永不疲倦、不断进化的**数字投资合伙人团队**。

1.3 解决的核心问题

- **投研效率**：7×24小时运转，将尽调周期从数周缩短至数小时
- **专业盲区**：7位专家Agent覆盖战略/行业/财务/法务/风控全维度
- **知识流失**：机构智慧资产沉淀，新人也能调用"老司机"经验
- **决策追溯**：20年+完整审计链，每次决策有据可查

二、作品描述：亮点与特点

2.1 核心亮点：数字投资天团

不是"AI辅助工具"，而是"数字投资合伙人"

角色单元	职责定位
红队（看多）	战略专家、行业专家，负责增长逻辑、市场空间与投资上行空间判断
蓝队（看空）	财务专家、风控专家，负责财务可持续性、风险暴露与下行情景识别
黄队（务实）	法务专家，负责交易结构、合规边界、核心条款与权责清晰度审查
主席（裁决）	投委会主席，综合多方意见进行权衡、裁决与最终建议输出
秘书（Coordinator）	负责流程编排、任务分发、跨角色同步与结论归档

协同机制：

- 红蓝黄三队提供独立视角，避免单一叙事主导判断
- 主席负责聚合分歧并形成投委会可执行结论
- Coordinator保证节奏一致、材料完整、过程可追溯

特点：

- **专业化分工**：每位Agent深耕一个领域，超越通才
- **对抗式投研**：红蓝交锋暴露盲区，逼近真相
- **双重模式**：既可7人协同投研，也可单Agent独立提供专业服务（如法律Agent出具法律意见书）

2.2 核心功能

功能模块	说明
六阶段投研流程	项目准入→信息复核→R1首轮→R2交锋→R3对抗→归档
三级人类决策点	底稿入库/差异复核/归档审核，人类拥有最终控制权
红蓝黄对抗机制	看多vs看空vs务实裁决，最大程度消除认知盲区
Agent自我进化	人工审核后知识自动入库，机构智慧资产复利增长
全程可追溯	20年+审计链，完整记录每个决策点

2.3 核心优势：DGX Spark 小身材大算力

为什么选择DGX Spark?

特性	DGX Spark优势
算力密度	128GB显存单台支撑7-Agent + 35B大模型并发
办公室友好	<35dB零噪音、<300W低能耗，办公桌下可放
数据主权	本地化部署，敏感投资数据不出机房
极致性价比	一次性投入，零Token费用，相比GPT-4节省80%+

三、技术创新点：NVIDIA技术栈深度应用

3.1 核心技术创新

创新一：共享专家模型 + 独立协调模型架构

- **6位专家共享** Qwen3.5-35B-A3B-FP8模型（Ollama部署）
- **Coordinator独立模型**：Nemotron-Cascade-2-30B-A3B 作为 `IC_Master_Coordinator` 专职承担协调与编排
- **独立知识库**：9个Milvus Collections（7私有+1共享+1归档）
- **角色隔离**：System Prompt定义专业身份，知识物理隔离

创新二：**262K超长上下文（行业首创）**

- **Qwen3.5-35B** 支持26.2万token上下文
- R3对抗时可完整读取R1全部6份报告+R2交锋记录
- **无需摘要压缩**，确保决策依据完整性

创新三：全**GPU流水线（DGX Spark专属优化）**

```
PDF/图片 → [Qwen3-vl-Embedding GPU] → 1024-dim向量
→ [Milvus HNSW GPU索引] → <10ms检索
→ [Qwen3.5-35B FP8 GPU推理] → 输出
```

创新四：**Recall-Think-Remember记忆闭环**

- **Milvus语义检索** (<150ms) + **轻量模型总结** + **大模型生成**
- Token消耗降低**80-90%**，真正实现永久记忆

3.2 NVIDIA工具平台与开源模型

技术组件	选型	作用
NVIDIA DGX Spark	GB10, 128GB Unified Memory	边缘AI超算，单机支撑全系统
CUDA	GPU加速全链路	Embedding+检索+推理全GPU
Blackwell FP8	Tensor Core加速	35B模型量化推理，节省43%显存
Qwen3.5-35B-A3B-FP8	阿里开源大模型	262K上下文，中国金融语义优化
Nemotron-Cascade-2-30B-A3B	NVIDIA开源协调模型	作为 `IC_Master_Coordinator` 独立协调任务分发与流程编排
Qwen3-vl-embedding-2b	多模态Embedding	支持PDF+图片向量化
Milvus 2.6.13	GPU向量数据库	9个Collections，HNSW GPU索引
Ollama	本地模型服务化	一键部署，API兼容
OpenClaw	开源Agent框架	Multi-Agent编排，会话持久化

3.3 自研技术亮点

- **GPU L2归一化**（CuPy加速）：向量归一化在GPU完成
- **空间PDF解析**（PyMuPDF）：保留版面信息，支持图文混排
- **断点续传机制**：JSON日志记录，中断后从断点继续
- **自研工作流引擎**：六阶段编排，支持三级人类决策点

四、团队贡献

角色	贡献
项目负责人	系统架构设计、OpenClaw Agent框架配置、Milvus数据库设计
算法工程师	知识入库脚本开发（V5.8）、RAG检索优化、Embedding pipeline
投资专家	7-Agent角色定义（SOUL.md）、六维评估框架、投研流程设计

协作方式：	投资专家提供业务逻辑，技术团队实现Agent编排与知识库构建，紧密协作完成系统。

五、未来展望

近期（2026 Q2）

- **Nemotron-Cascade-2-30B-A3B** 作为 `IC_Master_Coordinator` 独立协调模型，提升调度稳定性
- **钉钉/飞书机器人**接入，IM场景直接调用专业Agent
- **单Agent专家模式**：法律/财务Agent独立对外提供专业服务

中期（2026 Q4）

- **多机集群扩展**：多台DGX Spark水平扩展，支撑更大规模
- **自动报告生成**：一键生成Word/PDF投决报告
- **投后管理模块**：持续监控被投企业经营状况

远期（2027）

- **NemoClaw沙箱运行**：企业级安全隔离，代码执行可控
- **预测性分析**：基于历史数据预测项目成功率
- **跨机构知识联邦**：隐私计算下的行业知识共享

六、项目影响力与社会价值

6.1 重塑一级市场投资工作方式

- 从"个人经验依赖"到"数字合伙人协作"
- 从"不可追溯的口头决策"到"全程留痕的数据驱动"
- 从"知识随人走"到"机构智慧资产复利增长"

6.2 技术开源与生态贡献

- 全栈自研脚本开源，降低行业技术门槛
- OpenClaw + Milvus + DGX Spark最佳实践
- 为AI Agent在金融领域落地提供标杆案例

6.3 数据主权与合规

- **本地化部署**：敏感投资数据不出机房
- **人类控制权**：三级决策点确保AI辅助而非替代
- **监管友好**：20年+审计链满足金融监管要求

Sovereign-IQ：主权在握，智感未来。

用NVIDIA DGX Spark的小身材，撑起中国一级市场投资的大算力未来。

第二部分：系统角色与工作机制

第一章：七位Agent角色详解

2.1 IC_Master_Coordinator | 投委会秘书/协调者

角色定位：	系统的"指挥中枢"和"流程管家"

核心职责：

- **流程控制**：六阶段尽调流程的orchestration
- **任务调度**：并行/串行任务编排，确保R1→R2→R3顺畅衔接
- **独立协调模型**：Nemotron-Cascade-2-30B-A3B 专职承担协调、分发与节奏控制
- **质量把关**：信息质量评分卡（L1-L4），企查查MCP交叉验证
- **审计链生成**：完整决策记录，20年+保存
- **跨Agent协调**：6位专家的任务分发与进度监控

管理模型：	DAG（有向无环图）任务编排

IC_Finance_Auditor

Barrier ——— IC_Chairman

IC_Sector_Expert

IC_Strategist

Barrier ——— IC_Chairman

IC_Legal_Scanner

使用工具：

- **企查查MCP**：工商信息、风险信息、知识产权、经营信息核验
- **Tavily/Exa搜索**：公开信息交叉验证
- **Milvus向量库**：知识库存储与检索
- **OpenClaw Subagent管理**：任务分发与状态监控

判断标准：

- 信息质量等级：L4可信/L3可靠/L2存疑/L1危险
- 流程完成度：≥5位Agent完成发言
- 异常信号：数据矛盾>20%、关键信息缺失、合规风险

特点：	冷静、条理清晰、执行力强、注重细节、永不越界

2.2 IC_Strategist | 宏观战略专家

角色定位：	"站在月球看地球"——望远镜型思维

核心职责：

- **全球政经格局**：中美关系、科技战走向、供应链重构
- **政策趋势分析**：国家战略（半导体/AI/新能源）、监管信号（绿灯/黄灯/红灯）
- **资本流向追踪**：政府引导基金、市场化机构、外资趋势
- **经济周期判断**：复苏/过热/衰退/萧条期的投资策略
- **赛道配置建议**： 优先/ 关注/ 谨慎

分析框架：

地缘政治风险评估：

- 中美关系影响：[高/中/低]
- 供应链风险：[关键零部件/替代难度]
- 结论：[可投/谨慎/规避]

资金流向分析：

- 当前市场资金偏好：[早期/成长/后期]
- 项目匹配度：[政府基金/机构/CVC]
- 融资建议：[规模/节奏/接触资金类型]

经济周期判断：

- 当前阶段：[复苏/过热/衰退/萧条]
- 对项目影响：[融资环境/估值压力/退出窗口]
- 投资策略：[增配早期/聚焦盈利/防御为主/现金为王]

使用工具：

- **宏观经济数据库**：GDP、PMI、信贷数据、消费指数
- **政策监测工具**：国务院、证监会、发改委政策追踪
- **资本流向监测**：清科、投中、IT桔子融资事件分析
- **地缘政治风险模型**：供应链地理分布、关税影响分析

判断标准：

- 赛道政策评级： 强支持/ 中性/ 限制
- 时代趋势契合度：[高/中/低]

- 资本热度：[高/中/低]
- 全球格局位置：[领先/追赶/起步]

管理模型：	PESTEL宏观分析模型 + 波特五力行业定位

红线（绝不触碰）：

- 否 不分析公司产品技术细节（Sector Expert负责）
- 否 不评估公司团队能力（Sector Expert负责）
- 否 不计算具体财务指标（Finance Auditor负责）
- 否 不做具体风险清单（Risk Controller负责）

特点：	望远镜思维、政策敏感、资本嗅觉、周期意识、永远看远方

2.3 IC_Sector_Expert | 行业专家

角色定位：	"赛道深度研究员"——数据驱动的行业洞察

核心职责：

- **市场规模测算**：TAM/SAM/SOM三维度测算
- **竞争格局分析**：CR4集中度、五力模型、主要竞争者对标
- **技术路线评估**：技术成熟度曲线、专利壁垒、商业化进度
- **生命周期判断**：导入/成长/成熟/衰退/颠覆期识别

核心方法论：

TAM (总可服务市场) = 目标用户数 × 年均付费 × 渗透率

SAM (可服务市场) = TAM × 业务覆盖范围

SOM (可获得市场) = SAM × 市场份额目标 × 竞争强度系数

竞争态势五维度：

1. 市场集中度：CR4 < 30%分散 / 30-60%形成中 / >60%寡头
2. 竞争强度：价格战频率、营销投入、创新迭代速度
3. 进入壁垒：技术壁垒、网络效应、规模经济、监管壁垒
4. 替代威胁：替代技术成熟度、用户转换成本
5. 客户议价能力：客户集中度、切换成本、信息透明度

使用工具：

- **行业数据库**：艾瑞、易观、Gartner、IDC行业报告
- **专利检索系统**：国家知识产权局、Google Patents
- **竞品监测工具**：App Annie、Sensor Tower、SimilarWeb
- **技术成熟度评估**：Gartner Hype Cycle、TRL技术就绪等级

判断标准：

- 技术成熟度：[导入/成长/成熟/衰退/颠覆]

- 核心性能 vs 竞品：[领先/持平/落后]
- 市场份额目标：[X]%
- 赛道推荐指数：[X]/10

管理模型：	技术成熟度曲线 + 行业生命周期理论 + 竞争战略五力模型

输出标准：

- 赛道深度研究报告（TAM/SAM/SOM）
- 竞争格局分析（CR4、主要竞争者）
- 技术路线评估（成熟度、对比、风险）
- 生命周期判断（当前阶段、未来趋势）

特点：	数据驱动、深度钻研、对标思维、前瞻判断

2.4 IC_Finance_Auditor | 财务审计委员

角色定位：	"财务守门人"——数字背后的真相挖掘者

核心职责：

- **估值分析**：阶段适配的估值方法（VC Method/DCF/可比公司）
- **财务建模**：营收、利润、现金流预测模型
- **现金流分析**：Burn rate、Runway、Path to profitability
- **并表/审计调整**：财务数据质量验证、会计政策一致性

核心原则：

1. **Valuation follows stage**：
- 种子轮：Team + Vision > Financials
- A轮：Traction + Unit economics > Story
- B轮+：Scalability + Profitability > Growth at all costs
2. **Cash is reality**：Burn rate和Runway是不可妥协的指标
3. **Quality of growth**：
- Organic vs Paid growth
- Recurring vs One-time revenue
- Gross margin trajectory

估值方法论库：

早期项目（Seed/Pre-A）：

- Berkus Method：技术、执行、战略关系、生产、销售

- Scorecard Method：团队、规模、技术、竞争、渠道

成长期项目（A/B轮）：

- VC Method：退出估值 × 概率 × 稀释倍数

- Revenue Multiple：可比公司PS倍数

成熟期项目（C/Pre-IPO）：

- DCF：现金流折现模型
- EV/EBITDA：企业价值倍数
- 可比公司法：Precedent Transaction Analysis

使用工具：

- **财务数据库**：Wind、Bloomberg、Capital IQ
- **估值模型库**：VC Method、DCF、LBO、Comparable Company
- **审计调整工具**：收入确认政策、费用资本化、关联交易核查
- **IPO标准库**：科创板、创业板、港股上市财务标准

判断标准：

- 量化评分：0-10分制
- 置信度：High（审计报告验证）/Medium（管理层披露）/Low（假设推算）
- 数据源：Verified（第三方验证）/Assumed（管理层提供）
- 估值合理性：[低估/合理/高估] vs 可比公司

管理模型：	价值投资安全边际 + 风险投资阶段适配 + 财务审计谨慎性

红线：

- 否 不编造或估算数据作为事实
- 否 必须区分验证数据和假设数据
- 否 不单独做出投资决策

特点：	精准、审慎、平衡、务实、保护委员会

2.5 IC_Legal_Scanner | 法务合规委员

角色定位：	"法律放大镜"——微观合规风险专家

核心职责：

- **公司主体与股权结构**：设立合法性、股权清晰度、实际控制人
- **重大合同审查**：客户合同、供应商合同、关联交易、政府合同
- **知识产权**：专利（300+件验证）、商标、著作权、商业秘密
- **劳动人事**：劳动合同、竞业禁止、股权激励、社保公积金
- **诉讼与处罚**：未决诉讼、行政处罚、失信被执行人
- **行业资质与许可**：必备资质、有效期、合规经营
- **数据合规PIPL**：隐私政策、数据出境、算法备案
- **TS条款法律风险**：反稀释、清算优先、回购、保护性条款

微观合规风险框架：

风险评级：

低风险：股权清晰、无代持、无纠纷、IP无纠纷
中风险：存在1-2个可接受问题，可谈判解决
高风险：核心代持/IP纠纷/无证经营/严重条款偏颇
TS条款关键审查点：
- 反稀释条款：[完全棘轮/加权平均] 是否过于严苛？
- 清算优先权：[1x/2x/参与] 是否影响创始人利益？
- 回购条款：触发条件、回购利率、期限是否合理？
- 保护性条款：否决权范围是否限制正常经营？
- VIE架构：合规性、外资禁入问题

使用工具：

- **法律数据库**：北大法宝、威科先行、LexisNexis
- **知识产权检索**：国家知识产权局、商标局、版权局
- **诉讼查询**：裁判文书网、执行信息公开网、企查查司法风险
- **合同模板库**：TS协议、股东协议、竞业协议标准模板
- **合规检查清单**：PIPL合规、数据出境安全评估、行业资质要求

判断标准：

- 法律综合风险：[低/中/高]
- 8个维度分项评级
- 红线问题（致命）
- 需关注问题（可谈判）

管理模型：	法律风险矩阵 + 合同条款清单审查 + 合规性检查表

三级风控中的位置：

- Strategist（宏观）：政策/周期/格局
- Risk Controller（中观）：市场/舆情/竞争
- **Legal Scanner（微观）**：合同/IP/诉讼/TS条款

特点：	放大镜思维、保守稳健、文档驱动、清晰表达、宁可错杀不可放过

2.6 IC_Risk_Controller | 风险管理委员

角色定位：	"外部环境雷达"——中观风险监测专家

核心职责：

- **市场风险**：市场规模萎缩、增速不可持续、渗透率天花板
- **ESG风险**：环境（碳排放、能耗）、社会（数据隐私、劳动用工）、治理（关联交易、信披）
- **舆情风险**：媒体舆情、社交媒体、投诉数据、员工评价
- **竞争格局风险**：市场集中度、竞争壁垒、价格战、新进入者、替代品威胁

- **供应链风险**：供应商集中度、进口依赖、地缘风险、备选方案
- **行业周期风险**：导入/成长/成熟/衰退期判断、周期性特征

风险监测框架：

舆情监测四维度：

1. 媒体舆情：主流媒体报道 [正面/中性/负面] [X]篇
2. 社交媒体：微博/微信/KOL态度 [支持/中立/反对]
3. 投诉数据：投诉平台 [X]条/季度，主要类型，解决率
4. 员工评价：脉脉/LinkedIn [X]条，平均评分，主要差评原因

ESG评级：

- 国际ESG评级：[A/B/C/D]
- 国内ESG评级：[M/C/W]
- 是否在禁止投资名单：[是/否]

使用工具：

- **舆情监测工具**：百度指数、微信指数、舆情监控系统
- **ESG数据库**：MSCI ESG、 Sustainalytics、商道融绿
- **供应链分析**：海关数据、供应商集中度分析、地缘政治风险地图
- **行业周期模型**：库存周期、产能周期、技术创新周期

判断标准：

- 中观风险综合等级：[低/中/高]
- 6个维度分项评级
- 早期预警信号识别

管理模型：	风险雷达扫描 + 早期预警机制 + 情景分析

红线：

- 否 不判断宏观政策走向（Strategist负责）
- 否 不判断经济周期位置（Strategist负责）
- 否 不审查法律合同细节（Legal Scanner负责）

特点：	雷达思维、早期预警、中性客观、危机意识、永远扫描

2.7 IC_Chairman | 投委会主席

角色定位：	"最终决策者"——战略方向把控与争议裁决

核心职责：

- **最终投资决策**：Go / No-Go / 附条件通过
- **争议裁决**：R3红蓝对抗中的最终评判
- **战略方向把控**：确保与SIQ基金战略一致

- **六维评估综合**：基于各专家报告的综合判断
- **决策文档化**：完整记录决策理由，20年+保存

分阶段六维评估权重：

维度	种子/天使	Pre-A/A	B轮	C/D轮	Pre-IPO
Team Execution	40%	30%	20%	15%	10%
Product Competitiveness	20%	25%	20%	15%	15%
Market Attraction	15%	20%	15%	10%	10%
Financial Reasonableness	5%	10%	25%	35%	40%
Risk Controllability	10%	10%	10%	15%	20%
Strategic Alignment	10%	5%	10%	10%	5%

决策框架：

Go / No-Go 决策规则：

1. 若项目触发红线事项，直接进入 `NO-GO`。
2. 若综合风险评分高于 `80`，直接进入 `NO-GO`。
3. 若存在黄线问题，则需要确认补充条款或整改路径；可谈判并可落实时继续推进，否则进入 `NO-GO`。
4. 未触发红线且风险可控的项目，进入下一轮尽调或投决流程。

评分阈值：

- `Score ≥ 7.5`：Recommend Invest
- `Score 6.0 - 7.5`：Recommend Caution
- `Score < 6.0`：Recommend No-Go

使用工具：

- **历史投决案例库**：过往投资决策回顾、成功/失败模式分析
- **决策框架库**：不同行业、不同阶段的标准决策流程
- **争议裁决 precedent**：类似争议的过往裁决标准
- **六维评分卡**：各阶段权重配置的动态调整

判断标准：

- 六维综合评分：[X]/10
- 核心优势：[列举]
- 关键风险：[列举] + 缓解措施
- 决策建议：[通过/否决/附条件通过]
- 核心依据：[一句话总结]

管理模型：	投资决策委员会治理 + 战略一致性检查 + 风险收益平衡
特点：	果断、战略思维、公平、透明、负责任、建立传承

第二章：工作机制与流程

3.1 六阶段投研流程

```
阶段0：项目准入（人类决策点1）
人类上传底稿
AI解析+向量化（临时库）
生成《入库审核报告》
人类确认 → 确认入库 / 要求补充 / 拒绝入库
阶段1：信息差异复核（人类决策点2）
基于已入库底稿，启动企查查MCP核验
工商信息、风险信息、知识产权、经营信息交叉验证
差异对比：底稿数据 vs 外部数据
生成《差异提醒报告》
人类确认 → 继续投研 / 暂停补充 / 终止项目
阶段2：R1首轮讨论（Coordinator监督，自然节奏）
1    Strategist（战略专家）
2    Sector Expert（行业专家）
3    Finance Auditor（财务专家）
4    Legal Scanner（法务专家）
5    Risk Controller（风控专家）
6    Chairman（主席点评，可选）
阶段3：R2红黄蓝交锋（Coordinator主持）
黄队设定议题（基于R1分歧）
红队立论（看多）
蓝队立论（看空）
黄队裁决（设定R3务实议题）
阶段4：R3红蓝对抗（Coordinator主持）
// ... (truncated)
```

3.2 三级人类决策点与信息控制

决策点1：底稿入库确认

- **触发**：人类上传项目底稿
- **人类权力**：入库审核权（通过/补充/拒绝）
- **核心原则**：未经人类确认，文档不得进入正式库
- **控制机制**：AI解析→生成审核报告→人类三选一

决策点2：信息差异复核确认

- **触发**：Coordinator完成信息复核
- **人类权力**：流程决策权（继续/暂停/终止）
- **核心原则**：无论有无异常，均需人类确认"是否继续"
- **控制机制**：差异对比→生成提醒报告→人类知情后决策

决策点3：归档入库确认

- **触发**：投研决策结束
- **人类权力**：归档审核权（全选/部分/编辑/拒绝）
- **核心原则**：未经人类确认，任何文件不得进入长期存储
- **控制机制**：AI整理清单→人类审核→确认后入Milvus

3.3 三级风控体系

风控层级	对应角色	重点关注	核心问题
宏观层	Strategist	全球政经格局、政策趋势、资本流向、经济周期、地缘政治、赛道推荐	赛道宏观环境是否支持投资成立？
中观层	Risk Controller	市场风险、ESG风险、舆情风险、竞争格局、供应链风险、行业周期	公司外部环境是否存在重大经营风险？
微观层	Legal Scanner	合同条款、IP 权属、诉讼风险、TS条款、股权结构、资质许可、数据合规	法律与交易结构层面是否存在硬伤？

使用方式：

- 宏观层判断赛道与周期
- 中观层判断行业与经营外部性
- 微观层判断交易结构与合规可落地性

风控覆盖维度：

- **宏观层**：政策风险、周期风险、格局风险（战略层）
- **中观层**：市场风险、ESG风险、舆情风险、竞争风险（操作层外部）
- **微观层**：法律层硬伤、合规风险、条款风险（执行层）

3.4 信息多重确认与复核机制

第一重：底稿自洽性检查

- AI解析底稿时，检查内部逻辑一致性

- 标记数据矛盾点（如营收与增速不匹配）

第二重：外部数据交叉验证

- 企查查MCP四端点核验：工商、风险、知识产权、经营
- Tavily/Exa公开信息搜索：融资、IPO、行业对比

第三重：多Agent独立验证

- R1阶段6位专家独立发表观点
- 每位专家基于同一底稿，从不同维度验证

第四重：红黄蓝对抗辩论

- R2/R3阶段红蓝双方观点交锋
- 通过对抗暴露盲区，逼近真相

第五重：主席综合裁决

- Chairman基于全部信息做出最终判断
- 综合六维评分，给出决策建议

第三章：协同机制与自我进化

4.1 Agent协同机制

信息共享机制

```
共享库（ic_collaboration_shared_ws）：
所有Agent可读（只读权限）
R1发言实时写入
R2/R3讨论记录实时写入
后续Agent可基于前文发表更深入观点
私有库（ic_[agent]_ws）：
仅对应Agent可读写
专业知识沉淀
经验积累
其他Agent不可访问（知识隔离）
```

任务分发机制

- **Coordinator**负责任务 orchestration
- **R1**：严格顺序分发（战略→行业→财务→法务→风险→主席）
- **R2**：并行分发给红黄蓝三队
- **R3**：顺序分发（红→蓝→主席）

冲突解决机制

- **数据冲突**：差异>20%提交Chairman裁决
- **观点冲突**：R3红蓝对抗，主席最终裁决
- **流程冲突**：Coordinator协调，必要时人类介入

4.2 自我进化机制

讨论产生精华（R1/R2/R3自然产生）

↓

Coordinator提取（投研结束后）

↓

生成《知识进化提案》（AI生成）

新方法/新框架

新数据源

新判断标准

争议解决经验

↓

人类确认

确认入库 → 写入对应Agent私有库

修改后入库 → AI修改后重新提交

否 拒绝入库 → 记录原因

↓

知识入库 & Agent进化

写入Milvus私有collection

更新Agent SKILL.md/TOOLS.md

标记来源（项目编号、时间、置信度）

下次投研自动调用新知识

进化示例：

- **Finance Auditor**在人形机器人项目中发现新估值方法
- 经人类确认后，写入`ic_finance_auditor_ws`
- 下次遇到类似项目时，自动调用"技术里程碑+订单密度"模型
- 输出更专业的财务分析报告

4.3 数据可塑性与安全性

数据可塑性

- **项目协作库**：临时存储，项目结束后可清空
- **归档库**：永久保存（20年+），支持历史回溯
- **私有知识库**：持续追加，Agent越用越聪明

数据安全性

- **知识隔离**：一人一库，防止知识污染
- **访问控制**：共享库只读，私有库读写隔离
- **审计留痕**：所有操作可追溯，20年+保存
- **人类控制**：三级决策点确保人类对信息的最终控制权

数据备份

- **全量备份**：定期备份所有Agent配置、知识库、会话历史
- **增量备份**：项目结束后归档备份
- **异地备份**：建议同步到外部存储

第四章：SIQ系统的独特价值

5.1 为什么一级市场需要SIQ?

痛点一：投资决策依赖个人经验，难以传承

- **SIQ解决**：Agent私有知识库让机构知识沉淀，新人也能调用"老司机"经验

痛点二：投研流程不规范，容易遗漏关键风险

- **SIQ解决**：六阶段标准化流程+三级风控体系，确保无死角

痛点三：投委会效率低，难以快速响应市场

- **SIQ解决**：7×24小时运转，人类只需在三个决策点介入

痛点四：决策不可追溯，投错不知为何

- **SIQ解决**：完整审计链，支持20年+回溯，每次决策有据可查

痛点五：中国市场政策风险高，合规要求严

- **SIQ解决**：Legal Scanner专注微观合规，Strategist监控宏观政策

5.2 SIQ vs 传统投研方式

维度	传统投研	SIQ智能投研
团队配置	1-2人负责一个项目	7位专家同时服务一个项目
风控覆盖	依赖个人经验	三级风控体系全覆盖
决策依据	主观判断为主	六维量化评分+对抗辩论

维度	传统投研	SIQ智能投研
知识传承	随人走，难以沉淀	Agent私有库持续进化
决策速度	数周甚至数月	标准流程数小时完成
可追溯性	文档散落，难以回溯	完整审计链，20年+保存
政策敏感	容易遗漏监管信号	Strategist实时监控

5.3 适用场景

最适合：

- 硬科技赛道（半导体、AI、机器人、新能源）
- Pre-IPO项目（财务、合规、IPO确定性要求高）
- 跨境项目（地缘政治、供应链风险复杂）

次适合：

- 消费互联网（市场变化快，需频繁更新知识库）
- 早期项目（团队评估权重高，AI辅助有限）

第五章：结语

SIQ不仅是一套技术系统，更是一种**投资理念的制度化表达**。它将我们过去二十年在中国一级市场的成功经验，转化为可复制、可进化、可追溯的智能基础设施。

在这个信息爆炸、竞争加剧的时代，**拥有SIQ，就意味着拥有一个永不疲倦、不断学习、严格风控的虚拟投委会**。它不会替代人类投资经理的直觉和判断力，但会成为你最可靠的智囊团，帮助你在复杂多变的市场中，做出更明智的决策。

Sovereign-IQ：主权在握，智感未来。

报告撰写人：	SIQ设计团队-数据锦衣卫
日期：	2026年4月9日
系统版本：	SIQ v2.0
联系：	[机构投资咨询请联系SIQ团队]

第三部分：技术架构深度

第一章：系统架构总览

2.1 整体技术架构

架构层级	核心组件	说明
基础硬件层	NVIDIA DGX Spark (GB10)	提供 `128GB Unified Memory`、Blackwell GPU 与低能耗静音运行环境
基础服务层	Ollama / Milvus 2.6.13 / OpenClaw	分别承担模型服务、向量数据库与多 Agent 运行时编排
模型层	Qwen3.5-35B-A3B-FP8 + Nemotron-Cascade-2-30B-A3B	前者支撑 6 位专家分析，后者由 `IC_Master_Coordinator` 独立承担协调
执行与协作层	RAG Pipeline / Agent Workers / Tools	分别负责检索增强、角色执行、自演化流程以及 MCP/API 工具接入

主链路说明：

1. DGX Spark 提供统一算力底座。
2. Ollama 托管共享模型，Milvus 提供向量检索能力，OpenClaw 承担工作流调度。
3. 6 位专家 Agent 基于共享模型实例运行，`IC_Master_Coordinator` 由 Nemotron-Cascade-2-30B-A3B 独立承担协调与编排。
4. RAG、工作流引擎与外部工具共同支撑检索、分析、裁决与归档。

2.2 核心技术创新

创新一：共享模型 + 独立知识库架构

设计决策：7个Agent共享一个Qwen3.5-35B模型实例

技术实现：

```
# OpenClaw Agent配置
{
  "id": "ic-strategist",
  "model": "ollama/qwen3.5:35b-a3b-fp8", # 共享模型
```

```
  "system_prompt": "SOUL.md", # 独立角色定义
  "knowledge_base": "ic_strategist_ws" # 独立知识库
}
```

优势：

- **显存效率**：35B-FP8约40GB，128GB可支撑7-Agent并发
- **角色隔离**：System Prompt定义专业身份
- **知识隔离**：Milvus Collection级别隔离
- **一致性**：同一模型底座确保输出风格统一

创新二：全GPU流水线

端到端GPU加速：

```
Input (PDF/Image/Text)
    ↓ GPU
[Qwen3-vl-embedding-2b] → 1024-dim Vector
    ↓ GPU
[Milvus HNSW GPU Index] → TopK Retrieval (<10ms)
    ↓ GPU
[Prompt Assembly] → Context + Query
    ↓ GPU
[Nemotron-Cascade-2-30B-A3B / IC_Master_Coordinator]
    ↓ GPU
[Task Routing / Agent Orchestration]
    ↓ GPU
[Qwen3.5-35B-A3B-FP8] → Expert Analysis → Output
```

性能指标：

- Embedding：~100 docs/s (GPU)
- 检索延迟：<10ms (TopK=10, 1M vectors)
- 推理速度：~15 tokens/s (FP8)

创新三：Recall-Think-Remember 记忆闭环

用户提问

↓

[RECALL] Milvus AN语义检索 (<150ms)

↓

[THINK] Nemotron-Cascade-2-30B-A3B 协调判断关联性

↓

[REMEMBER] 提炼后上下文 → Qwen3.5-35B-A3B-FP8 生成

↓

新对话 → 向量化 → 沉淀回Milvus (闭环)

效果：

- Token消耗↓ 80-90%
- 检索延迟<150ms
- 永久记忆 + 拟人化时间排序

第二章：硬件基础设施 - DGX Spark详解

3.1 为什么选择DGX Spark?

传统方案的困境:

方案	问题
云端API	数据上云不安全，Token成本高昂，网络延迟
台式机+GPU	显存不足(24GB/48GB)，无法支撑35B模型
服务器集群	噪音大、能耗高、部署复杂、成本高昂
DGX Spark	128GB显存、低噪音、低能耗、易部署

3.2 DGX Spark技术规格

组件	规格	SIQ利用方式
GPU	NVIDIA GB10 (Blackwell)	LLM推理+Embedding+向量检索
显存	128GB Unified Memory	模型权重+KV Cache+向量索引
CPU	ARM64 (20-core)	OpenClaw运行时+业务逻辑
存储	4TB NVMe SSD	模型文件+知识库+日志
网络	10GbE	API调用(企查查/Tavily/Exa)
功耗	**<300W**	低能耗，适合长期运行
噪音	**<35dB**	几乎零噪音，办公室友好

3.3 显存分配策略

128GB Unified Memory分配:

Qwen3.5-35B-A3B-FP8专家模型权重: ~40GB

Nemotron-Cascade-2-30B-A3B协调模型权重: ~24GB

Qwen KV Cache (262K×6专家并发): ~32GB

Nemotron KV Cache (64K×1协调上下文): ~6GB

Milvus GPU索引缓存: ~10GB

Qwen3-vl-Embedding: ~8GB

系统预留+缓冲: ~8GB

为什么这样分配：

- **Qwen3.5-35B-A3B-FP8继续做专家分析主模型**：保留 262K 超长上下文，负责 6 位专家 Agent 的深度投研、长文档理解和跨轮次证据整合。
- **Nemotron-Cascade-2-30B-A3B独立做 Coordinator**：将 `IC_Master_Coordinator` 从专家分析模型中解耦，专职承担任务调度、流程编排、状态同步和工具路由。
- **Coordinator不需要复制专家级长上下文**：协调模型主要处理流程状态、摘要结论、工具调用结果和下一步动作，因此上下文窗口控制在 `64K` 更合理，把显存优先让给专家模型和检索缓存。
- **7并发改为6专家并发 + 1协调并发**：从"7个专家都挤在同一共享模型"改为"6个专家共享 Qwen + 1个 Coordinator 独立 Nemotron"，并通过分阶段调度压缩 KV Cache 峰值。
- **Milvus缓存下调是有意设计**：向量索引仍保留 GPU 常驻，但更多依赖热数据缓存，而不是为全量索引长期占满显存。

为什么选择 Nemotron-Cascade-2-30B-A3B：

- **更适合作为协调模型而非领域专家模型**：NVIDIA 官方将其定义为开源 `30B MoE / 3B 激活参数` 模型，强调 reasoning 与 agentic 能力，适合承担流程控制、任务拆解、工具编排和跨步骤状态管理。
- **同时支持 thinking 与 instruct 两种模式**：适合在"需要深思考时展开推理、需要执行调度时快速给出明确动作"的 Coordinator 场景中切换。
- **官方提供 262K 上下文与 vLLM 单卡部署范式**：说明其本身具备长上下文和工程可落地性，但在本系统中我们刻意将其用于更轻的协调上下文，以换取更稳的整体资源分配。
- **与 Qwen3.5-35B-A3B-FP8形成职责互补**：Qwen 负责"专业分析深度"，Nemotron 负责"流程协调效率"，避免一个模型既做专家推理又做流程编排导致上下文和 KV Cache 争抢。

关键设计：262K长上下文优化

- YaRN位置编码外推
- Ring Attention显存高效计算
- KV Cache压缩+滑动窗口

3.4 部署优势

Docker Compose一键部署：

```
# docker-compose.yml
version: '3.8'
services:
  milvus:
    image: milvusdb/milvus:v2.6.13-gpu
    deploy:
      resources:
        reservations:
          devices:
            - driver: nvidia
              count: all
              capabilities: [gpu]

  ollama:
    image: ollama/ollama:latest
    volumes:
      - ./models:/root/.ollama

  attu:
```

```
    image: zilliz/attu:latest
    ports:
      - "800:300"

  openclaw:
    image: openclaw/siq:latest
    volumes:
      - ./workspaces:/workspace
```

部署步骤：

1. `docker-compose up -d` (5分钟启动)
2. 导入模型 `ollama pull qwen3.5:35b-a3b-fp8`
3. 运行知识入库脚本
4. 开始投研

第三章：大模型层 - 262K超长上下文

4.1 Qwen3.5-35B-A3B-FP8技术解析

参数	值	说明
参数量	35B	总参数350亿
激活参数	A3B (3B)	MoE架构，每次前向激活30亿
量化精度	FP8	节省50%显存，Blackwell原生支持
上下文	**262K**	支持26.2万token超长上下文
架构	Transformer + MoE	混合专家模型

MoE优势：

- 推理成本低：每次只激活1/10参数
- 性能不减：35B MoE ≈ 70B Dense效果
- 显存友好：FP8量化后仅需35-40GB

4.2 262K上下文在SIQ的关键价值

传统模型的困境：

R1输出: ~8K × 6 Agents = 48K tokens

R2交锋: ~6K tokens

R3需要读取: R1+R2 = 54K tokens

32K/64K模型: 必须摘要压缩，信息损失严重

262K模型: 全量加载，无信息损失

SIQ场景验证：

- R3红蓝对抗时，Agent可完整阅读R1全部6份报告+R2交锋记录
- 无需摘要压缩，确保决策依据完整性
- 支持跨轮次深度推理和关联分析

4.3 金融领域优化

Qwen3.5的中国金融优势：

- 训练数据包含大量中文研报、财报、公告
- 对估值模型、融资条款、IPO流程深度理解
- 内置中国金融监管政策知识

对比测试：

任务	GPT-4	Claude 3	Qwen3.5-35B
财务术语理解	85%	82%	**94%**
IPO政策问答	78%	75%	**91%**
TS条款解析	88%	86%	**93%**
中文研报摘要	80%	79%	**95%**

4.4 Ollama部署优化

关键配置：

```
OLLAMA_CONTEXT_LENGTH: 262144
OLLAMA_NUM_PARALLEL: 7
OLLAMA_GPU_OVERHEAD: 1024MB
OLLAMA_FLASH_ATTENTION: true
```

并发策略：

- 7个Agent共享同一模型实例
- System Prompt区分角色身份
- KV Cache优化管理

4.5 协调模型：Nemotron-Cascade-2-30B-A3B 独立编排

规划方向：

- Coordinator独立部署 Nemotron-Cascade-2-30B-A3B
- 专职负责任务调度、流程编排与跨Agent状态同步
- 其他6位Expert继续使用Qwen3.5-35B

Nemotron-Cascade-2-30B-A3B 优势：

- NVIDIA 官方定义其为开源 `30B MoE / 3B 激活参数` 模型，具备强 reasoning 与 agentic 能力
- 支持 thinking / instruct 双模式，适合 Coordinator 在“深思考”和“直接执行”之间切换
- 官方提供 `vLLM + 262K context` 的工程部署方式，便于本地化落地
- 适合承担长流程、多阶段的协调与路由任务
- 便于将 `IC_Master_Coordinator` 与专家分析模型解耦
- 有利于提升并发调度稳定性和整体流程可控性

为什么不直接用它替代专家模型：

- `IC_Master_Coordinator` 的核心任务是调度，而不是财务、法务、行业等深度专业判断
- 专家模型更需要超长上下文下的细节保真，Coordinator 更需要稳定路由、摘要整合与工具编排
- 因此我们采用“Qwen 负责分析、Nemotron 负责协调”的双模型分工，而不是单模型全包

第四章：向量数据库层 - Milvus 2.6.13

5.1 Milvus架构设计

为什么选择Milvus?

- **GPU加速**：原生支持GPU索引，与DGX Spark完美契合
- **海量规模**：支持十亿级向量，机构知识持续增长无压力
- **灵活索引**：HNSW/GPU_CAGRA/IVF_FLAT多种索引可选
- **云原生**：分布式架构，未来水平扩展无忧

部署架构：

Milvus Standalone (DGX Spark)

Query Node (GPU) ← 向量检索

Index Node (GPU) ← HNSW构建

Data Node (CPU) ← 数据持久化

MinIO (本地) ← 对象存储

5.2 9个Collections设计

Collection	用途	当前规模	索引
ic_strategist_ws	战略专家私有库	1,466	HNSW
ic_sector_expert_ws	行业专家私有库	3,735	HNSW
ic_finance_auditor_ws	财务专家私有库	1,158	HNSW
ic_legal_scaner_ws	法务专家私有库	12,662	HNSW
ic_risk_controller_ws	风控专家私有库	1,218	HNSW

Collection	用途	当前规模	索引
ic_chairman_ws	主席私有库	1,568	HNSW
ic_master_cordinator_ws	协调者库	-	HNSW
ic_collaboration_shared_ws	项目协作库	722	HNSW
ic_archive_sop_ws	归档库(20年+)	-	HNSW

Schema设计：

```
fields = [
    FieldSchema(name="id", dtype=DataType.INT64, is_primary=True, auto_id=True),
    FieldSchema(name="vector", dtype=DataType.FLOAT_VECTOR, dim=1024),
    FieldSchema(name="project_tag", dtype=DataType.VARCHAR, max_length=128),
    FieldSchema(name="metadata", dtype=DataType.JSON),
]
```

索引配置：

```
INDEX_PARAMS = {
    "metric_type": "L2",
    "index_type": "HNSW",
    "params": {"M": 32, "efConstruction": 256}
}
```

性能指标：

- 插入速度：~10,000 vectors/s (GPU加速)
- 查询延迟：<10ms (TopK=10, 1M vectors)
- 召回率：>95% (vs 暴力搜索)

5.3 Qwen3-vl-embedding-2b多模态Embedding

参数	值
参数量	2B
输出维度	**1024** (精度与存储平衡)
输入模态	Text + Image
GPU加速	CUDA (Ollama部署)

多模态优势：

- PDF研报：文字+图表一并理解
- 股权结构图：图片中的股权比例直接量化
- 产品截图：视觉特征辅助行业分析

5.4 自研知识入库脚本 V5.8

技术亮点：

1. **GPU L2归一化**

```
def _gpu_l2_normalize(self, vectors):
    v_gpu = cp.array(vectors) # CuPy GPU数组
    norm = cp.linalg.norm(v_gpu, axis=1, keepdims=True)
    return (v_gpu / (norm + 1e-9)).get().tolist()
```

2. **物理IP锁定**
- 解决localhost丢包问题
- 使用固定LAN IP (192.168.110.85)

3. **空间PDF解析**
- PyMuPDF (fitz)提取文本块和坐标
- 保留版面信息，支持图文混排

4. **断点续传**
- `.ingest_log_{collection}.json`记录进度
- 中断后从断点继续

5. **OCR视觉补偿**
- PDF文本提取失败时自动OCR
- RapidOCR (ONXRuntime加速)

6. **状态机物理追踪**
- `incoming/` → `processed/` / `failed/`
- 目录流转实现任务状态管理

5.5 Attu可视化

功能：

- 9个Collections数据分布监控
- 向量检索结果可视化
- 索引性能实时监控
- 元数据过滤查询

部署：	Docker一键启动

```
docker run -p 800:300 zilliz/attu:latest
```

第五章：Multi-Agent架构实现

6.1 OpenClaw原生Agent框架

为什么选择OpenClaw?

特性	LangChain	LlamaIndex	OpenClaw
Agent生命周期	需自建	需自建	**原生支持**

特性	LangChain	LlamaIndex	OpenClaw
会话持久化	需自建	需自建	**内置**
Subagent管理	复杂	不支持	**原生支持**
知识库挂载	需集成	原生	**原生+隔离**
Human-in-loop	需自建	需自建	**三级决策点**
MCP工具	需适配	需适配	**原生支持**

6.2 7-Agent配置详解

```
{
  "agents": {
    "list": [
      {
        "id": "ic-strategist",
        "name": "SIQ战略专家",
        "model": "ollama/qwen3.5:35b-a3b-fp8",
        "workspace": "/workspace/ic_strategist_workspace",
        "system_prompt": "SOUL.md",
        "knowledge_base": "ic_strategist_ws",
        "tools": ["web_search", "web_fetch"]
      }
    ]
  }
}
```

角色定义（SOUL.md）：

- 每位Agent独立的SOUL.md定义专业身份
- 核心能力、边界、红线明确
- 输出格式、置信度标注标准化

6.3 Agent隔离机制

知识隔离：

```
class Agent:
    def retrieve_knowledge(self, query):
        # 强制只能访问自己的collection
        return milvus.search(
            collection_name=self.kb_collection,
            filter=f"agent_id=='{self.id}'"
        )
```

文件系统隔离：

```
/workspace/
ic_strategist_ws/
SOUL.md
memory/
tmp/
```

```
ic_finance_auditor_ws/
...
```

6.4 自研工作流引擎

为什么自研?

维度	Airflow	Prefect	自研
学习成本	高	中	**低**
灵活性	中	高	**极高**
Agent感知	无	无	**原生**
Human-in-loop	难	复杂	**内置**
延迟	秒级	秒级	**毫秒级**

六阶段工作流:

```
async def run(self):
    await self.stage1_project_admission() # 项目准入
    await self.stage0_info_verification() # 差异复核
    await self.stage2_r1_discussion() # R1首轮
    await self.stage3_r2_debate() # R2交锋
    await self.stage4_r3_confrontation() # R3对抗
    await self.stage5_archiving() # 归档
```

6.5 三级人类决策点

决策点1：底稿入库确认

- 触发：人类上传项目底稿
- AI：解析+生成审核报告
- 人类：确认入库/要求补充/拒绝

决策点2：信息差异复核

- 触发：Coordinator完成外部核验
- AI：差异对比+生成提醒报告
- 人类：继续投研/暂停补充/终止

决策点3：归档入库确认

- 触发：投研决策结束
- AI：整理13份文档清单
- 人类：全部/部分/编辑后入库/拒绝

第六章：工具集成与外部API

7.1 MCP工具架构

企查查API：

```
class QCCMCP:
    async def query_company(self, company_name: str):
        """查询企业工商信息"""
        response = await httpx.post(
            "https://agent.qcc.com/mcp/company/stream",
            headers={"Authorization": f"Bearer {token}"},
            json={"company_name": company_name}
        )
        return response.json()
```

Tavily/Exa搜索：

```
# Tavily深度研究搜索
async def tavily_search(query: str):
    return await httpx.post(
        "https://api.tavily.com/search",
        json={"query": query, "search_depth": "advanced"}
    )

# Exa语义搜索
async def exa_search(query: str):
    return await httpx.post(
        "https://api.exa.ai/search",
        json={"query": query, "type": "neural"}
    )
```

7.2 外部数据与内部数据隔离

设计原则：

- 外部数据（企查查/搜索）→ 仅用于差异复核
- 内部数据（项目底稿/投研报告）→ 存入Milvus长期保存
- 物理隔离：外部API调用结果不直接进入内部知识库

质量控制：

- 外部数据需经人类确认后才可入库
- 差异对比报告标记数据来源（Verified/Assumed）
- 防止外部污染数据影响投研质量

第七章：安全与审计

8.1 数据安全架构

三级隔离：

Level 1: Agent私有知识库隔离
每个Agent独立Milvus Collection
Collection级别RBAC权限
代码层强制agent_id过滤
Level 2: 项目级别隔离
project_tag字段过滤
同项目内Agent可共享
跨项目数据不可见
Level 3: 角色权限隔离
Coordinator: 全权限
Agent: 只读共享库，读写私有库
Human: 审核权+决策权

传输与存储加密：

- Ollama API: TLS 1.3
- Milvus gRPC: mTLS
- Milvus数据: AES-256-GCM静态加密
- 备份文件: GPG加密

8.2 审计日志系统

审计内容：

```
{
  "timestamp": "2026-04-09T10:30:00Z",
  "event_type": "human_decision",
  "decision_point": "project_admission",
  "operator": "user@siq.com",
  "project_id": "SIQ-UNITREE-2026-001",
  "decision": "approved",
  "ip_address": "10.0.0.1",
  "session_id": "e53b7023-312e-48e8-aee7-8c476959f174"
}
```

保存策略：

- 保存期限: 20年+ (符合金融监管)
- 存储位置: ic_archive_sop_ws (Milvus) + 冷备份
- 防篡改: 哈希链 + 数字签名

第八章：性能优化与未来演进

9.1 GPU性能优化

FP8量化推理：

```
FP16: 70GB VRAM, 10 tokens/s
FP8: 40GB VRAM, 15 tokens/s (节省43%, 加速50%)
```

KV Cache优化：

- 262K长上下文KV Cache管理
- 滑动窗口注意力
- 重要性采样压缩

9.2 未来演进路线

近期 (2026 Q2)：

- Nemotron-Cascade-2-30B-A3B 作为 IC_Master_Coordinator 独立部署
- 钉钉/飞书机器人接入
- 单Agent专家模式（如法律Agent独立服务）

中期 (2026 Q4)：

- 多机集群支持（水平扩展）
- 自动报告生成（Word/PDF）
- 投后管理模块

远期 (2027)：

- NemoClaw沙箱运行（企业级安全）
- 预测性分析（项目成功率预测）
- 跨基金知识联邦（隐私计算）

第九章：总结

10.1 核心创新价值

维度	传统方案	SIQ方案	优势
团队配置	1-2人/项目	7位专家Agent	**专业化分工**
决策质量	个人经验	六维评估+对抗	**盲区最小化**
知识传承	随人走	Agent自我进化	**机构资产沉淀**
数据安全	上云API	本地部署	**主权可控**
成本效率	Token燃烧	一次性投入	**80%+成本节省**

维度	传统方案	SIQ方案	优势
可追溯性	口头决策	完整审计链	**20年+可追溯**

10.2 DGX Spark：小机器大算力的完美诠释

128GB显存支撑：

- 35B大模型推理
- 7-Agent并发
- 262K超长上下文
- Milvus GPU索引
- 全部在一台桌面级设备完成

办公室友好：

- 低能耗（<300W）
- 零噪音（<35dB）
- 易部署（Docker一键启动）
- 数据本地化（符合监管）

10.3 重塑一级市场投资工作方式

SIQ不是替代投资人，而是为每位投资人配备一个：

永不疲倦的专业化投资天团

- 7位专家7×24小时待命
- 每位Agent深耕一个领域
- 既可协同投研，也可独立提供专业服务

人类主权保障

- 三级决策点确保最终控制权
- AI提供建议，人类做出决策
- 完整审计链支持决策复盘

机构智慧资产复利增长

- 每次投研沉淀知识
- Agent越用越聪明
- 形成机构专有竞争壁垒

Sovereign-IQ：主权在握，智感未来。

报告撰写人： 数据锦衣卫 **日期：** 2026年4月9日 **系统版本：** SIQ v2.0 Technical Architecture **联系：** [机构咨询请联系SIQ研发团队]